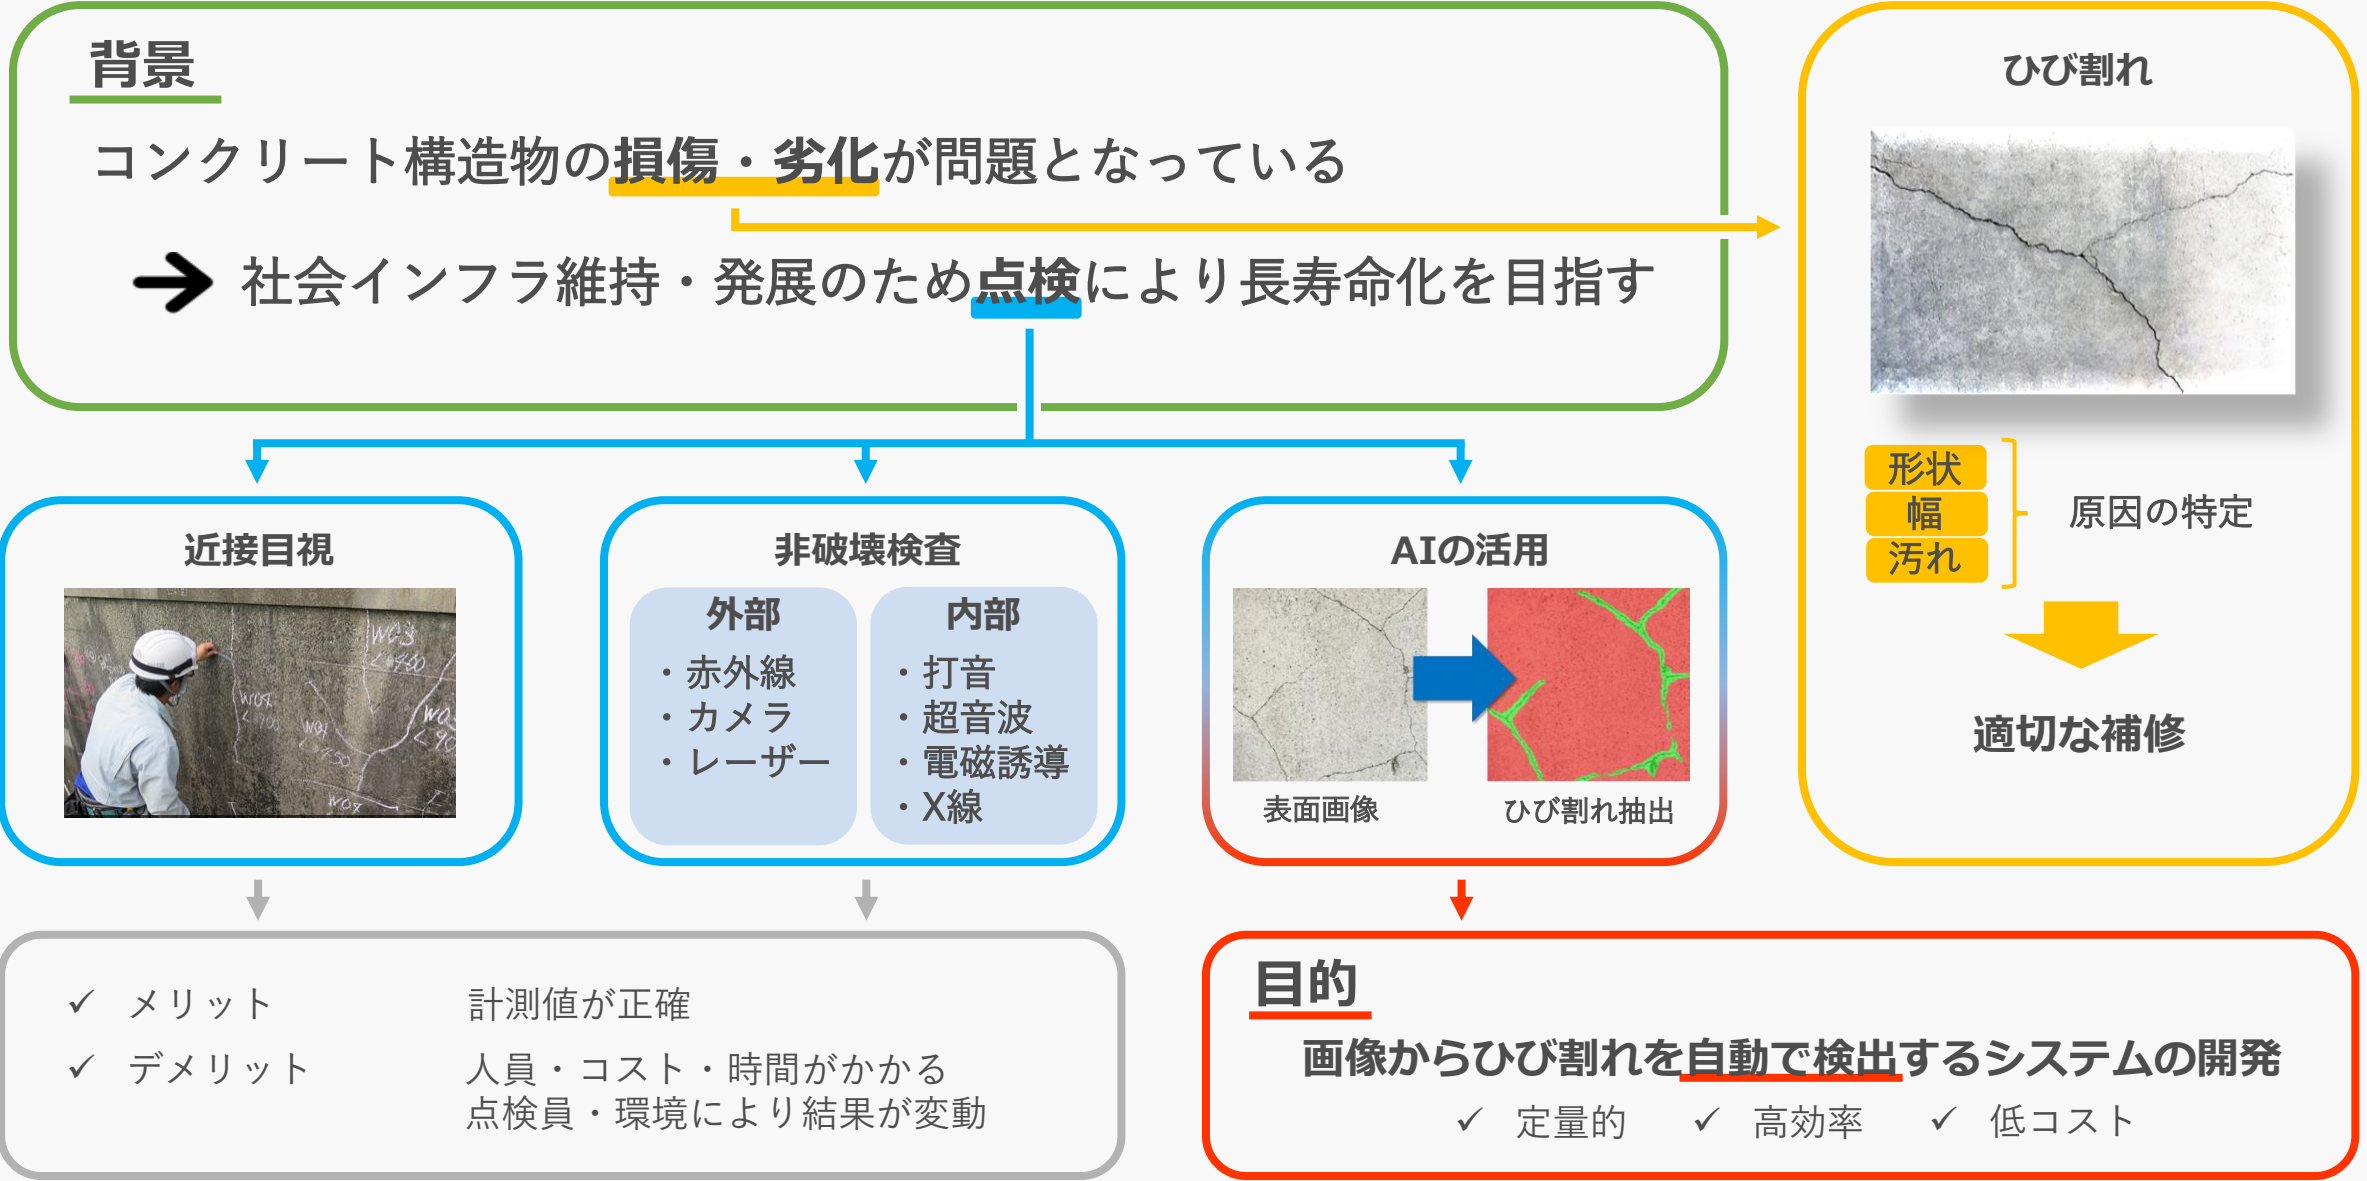


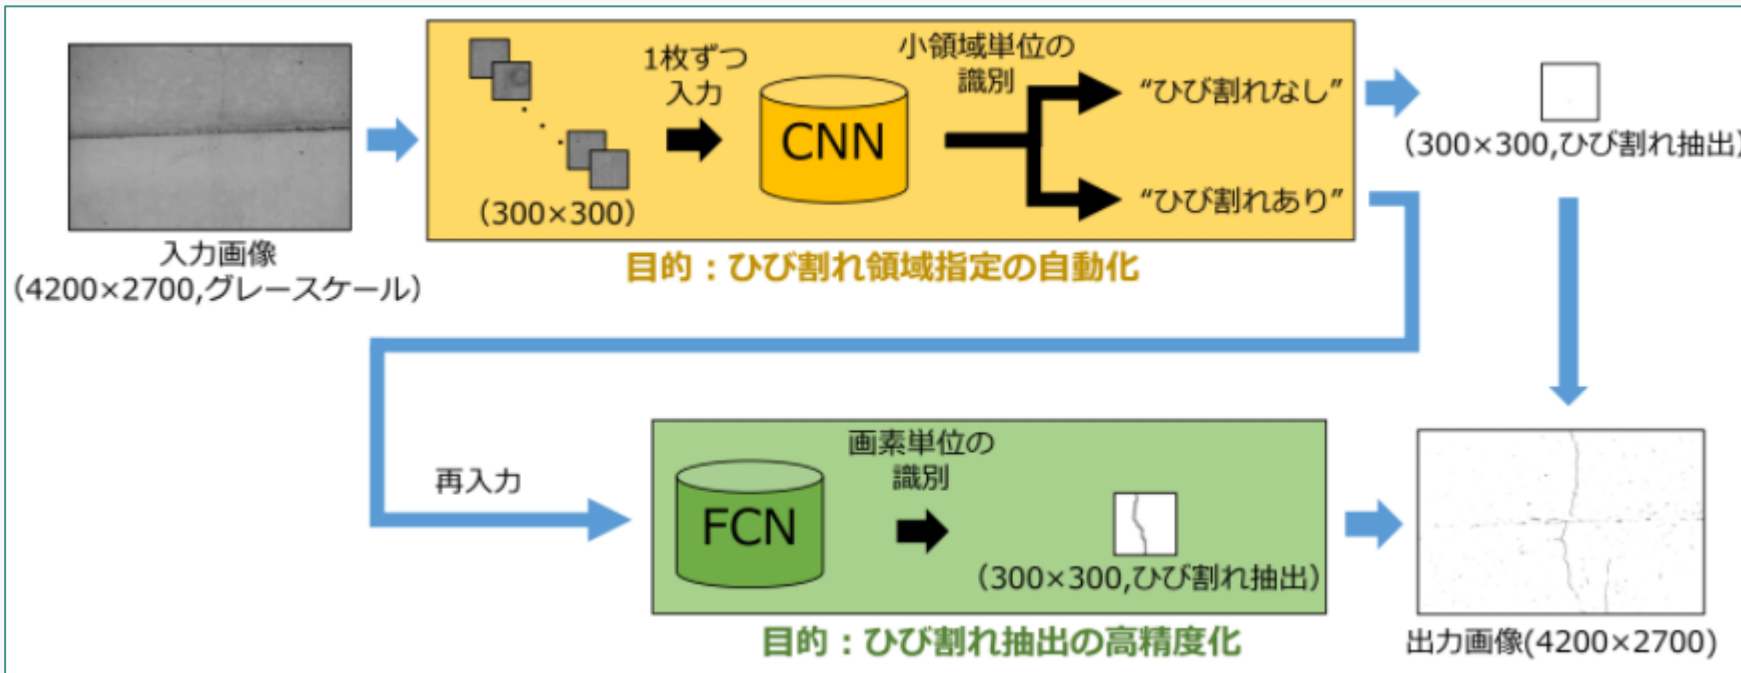
# 研究報告

---

田坂 祐紀



## ■ CNNとFCNを組み合わせたひび割れ自動抽出法



### 課題

- ・ 未検出により最終的なひび割れ抽出の未抽出が増加
- ・ ひび割れ画素数の少ない小領域の未検出が多い

### 学習

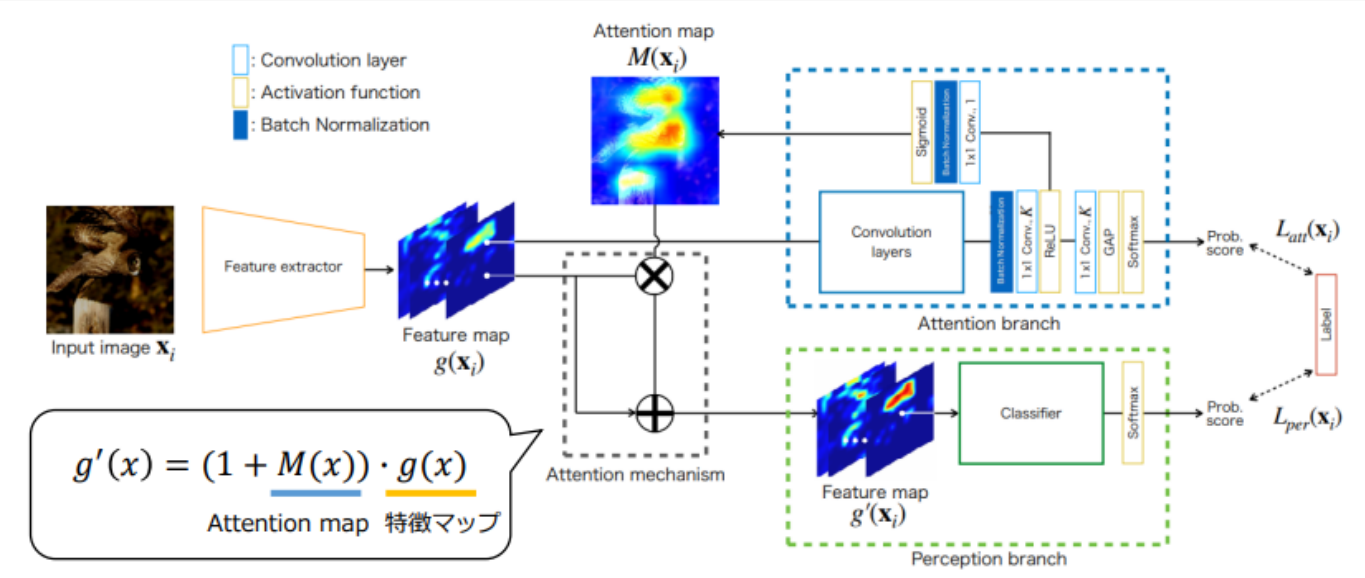
#### CNN

- 重なりを許しながら小領域を設定
- 小領域ごとのラベル付け
  - 小領域の1%以上がひび割れ画素 ⇒ ひび割れ **有り**
  - 小領域のひび割れ画素が1%未満 ⇒ ひび割れ **無し**
- ひび割れ有りクラスのみデータ拡張
  - 回転(90,180,270°) + コントラスト低減(33%)  
or  
平滑化(33%)

#### FCN

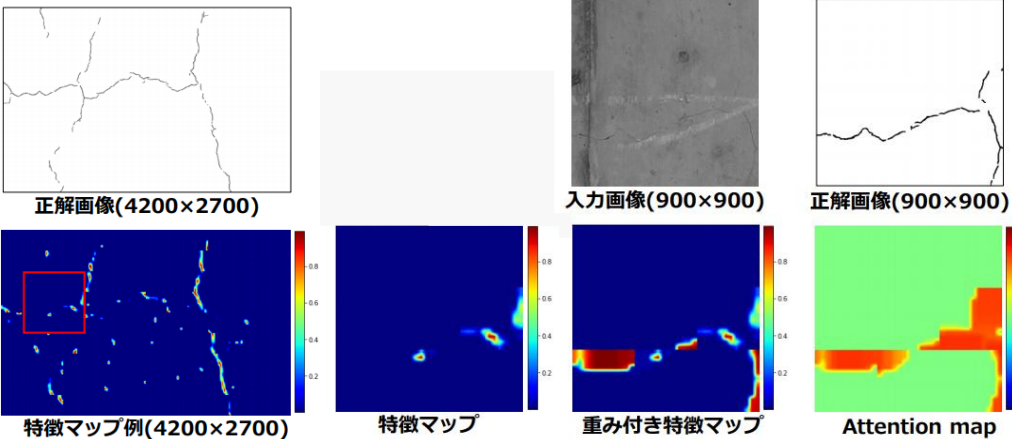
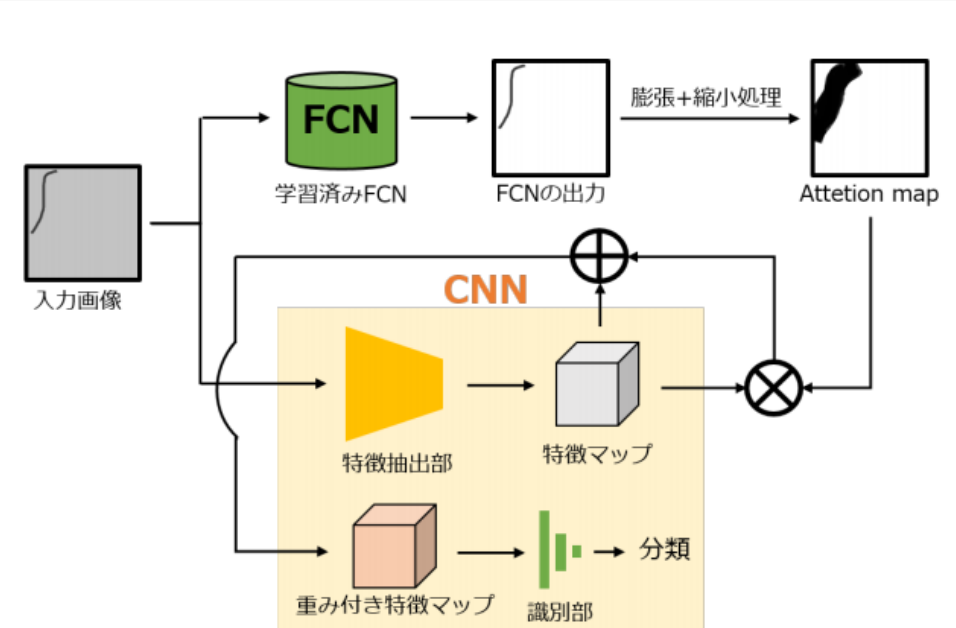
- 小領域の切り出し
- ひび割れ画素が含まれる小領域のみ使用
- データ拡張
  - コントラスト低減
  - 平滑化处理

FCNの出力をCNNの特徴マップの重み付けに用いたネットワーク

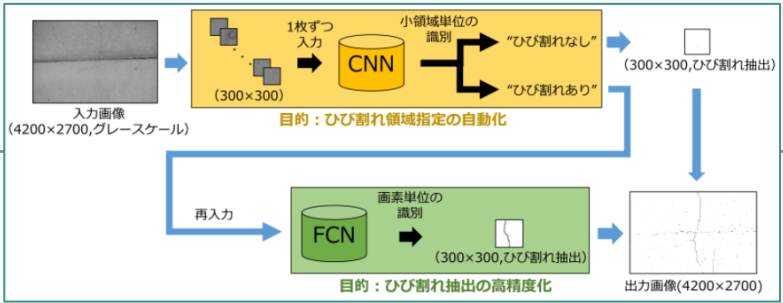


各組み合わせによるひび割れ抽出の適合率、再現率、F値の平均と標準偏差を示す

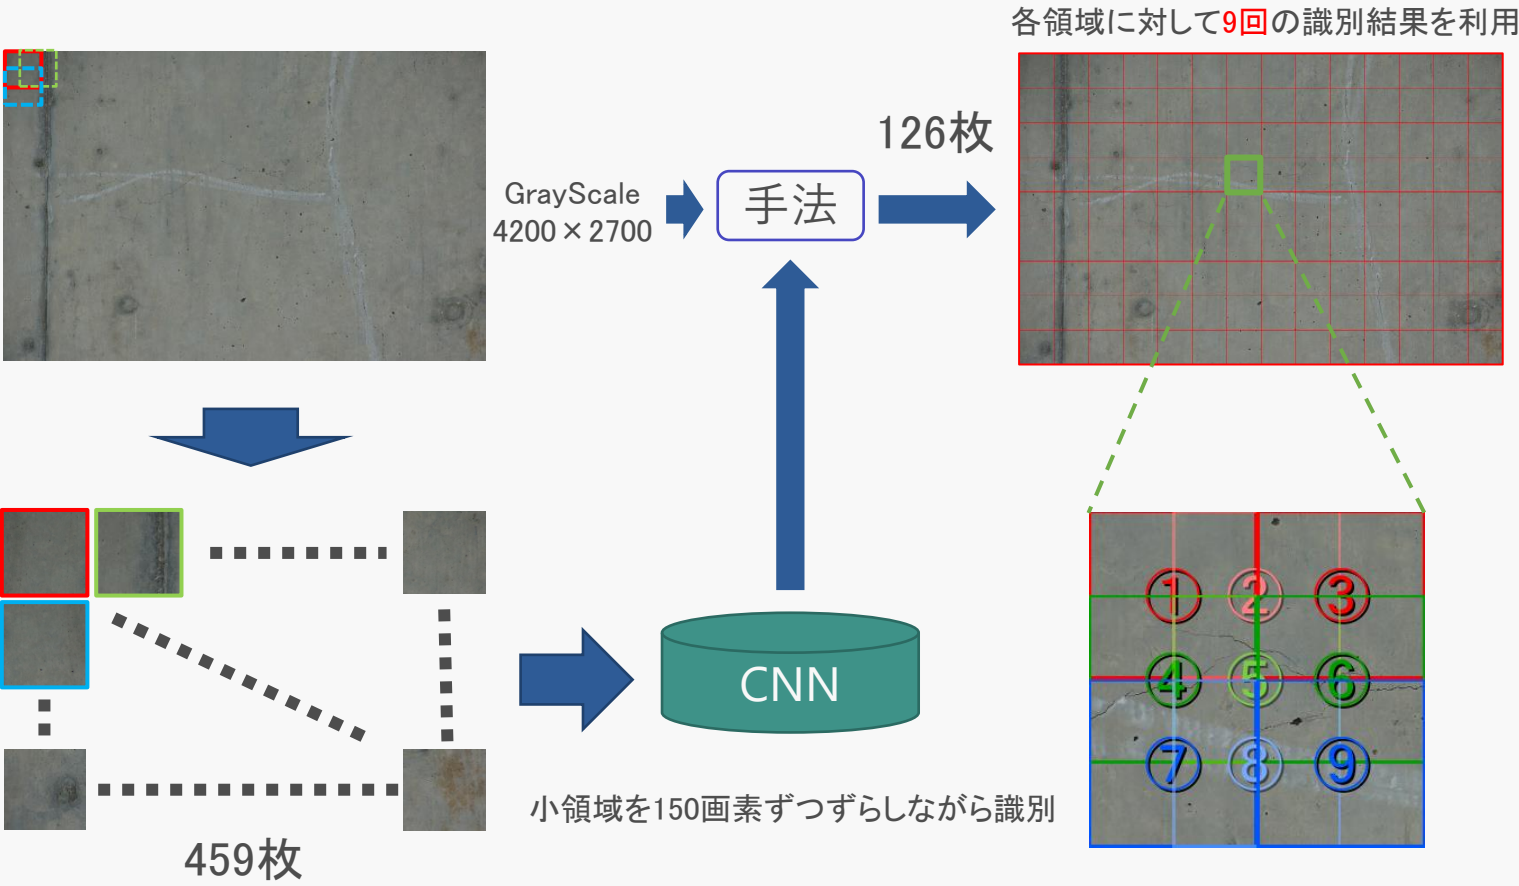
ひび割れ検出モデル	ひび割れ抽出法	適合率	再現率	F値
		0.875	0.855	0.864
CNN(ベースライン)	FCN	$0.961 \pm 0.009$	$0.809 \pm 0.035$	$0.875 \pm 0.022$
CNN(提案) Attention map : 尤度		$0.955 \pm 0.003$	$0.829 \pm 0.013$	$0.885 \pm 0.007$
CNN(提案) Attention map : 識別結果		$0.947 \pm 0.013$	$0.827 \pm 0.019$	$0.881 \pm 0.007$



従来手法のCNNの識別精度の改善(卒論の内容)



目的：学習済みモデルの識別結果を利用し、システム全体の識別精度の向上



**手法A**

多数決による  
クラス分類

1	1	1
1	1	1
0	0	0

0:ひび割れ無し  
1:ひび割れ有り

**手法B**


積の合計を正規化  
0.5以上⇒ひび割れ有り  
0.5未満⇒ひび割れ無し

1/4	1/2	1/4
1/2	1	1/2
1/4	1/2	1/4


識別結果に重み  
をかける

■ 比較


■:未検出  
■:正検出  
■:過検出



手法A



手法B



従来手法  
(多数決無し)

	適合率	再現率	F-値
手法A（重みなし）	0.9848	0.8496	0.9122
手法B（重み付き）	0.9496	0.8627	0.9041
従来手法（多数決なし）	0.9492	0.8562	0.9003

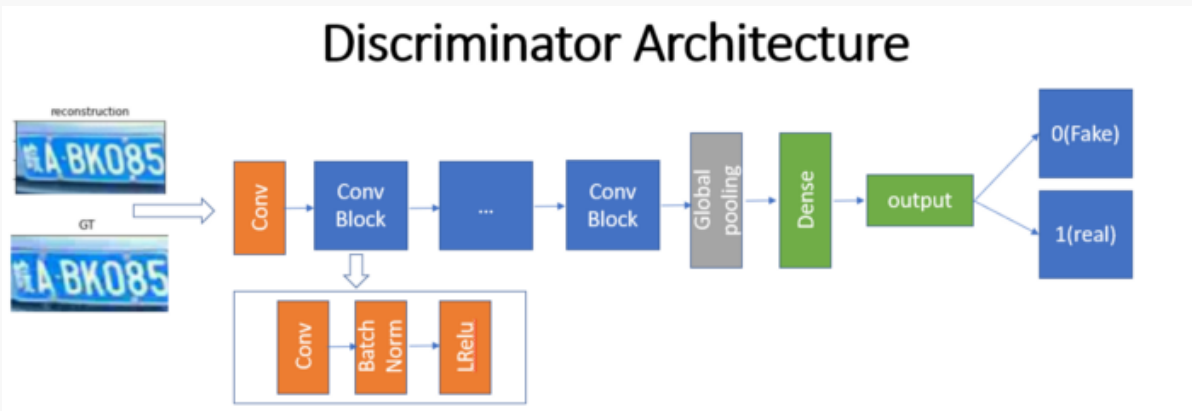
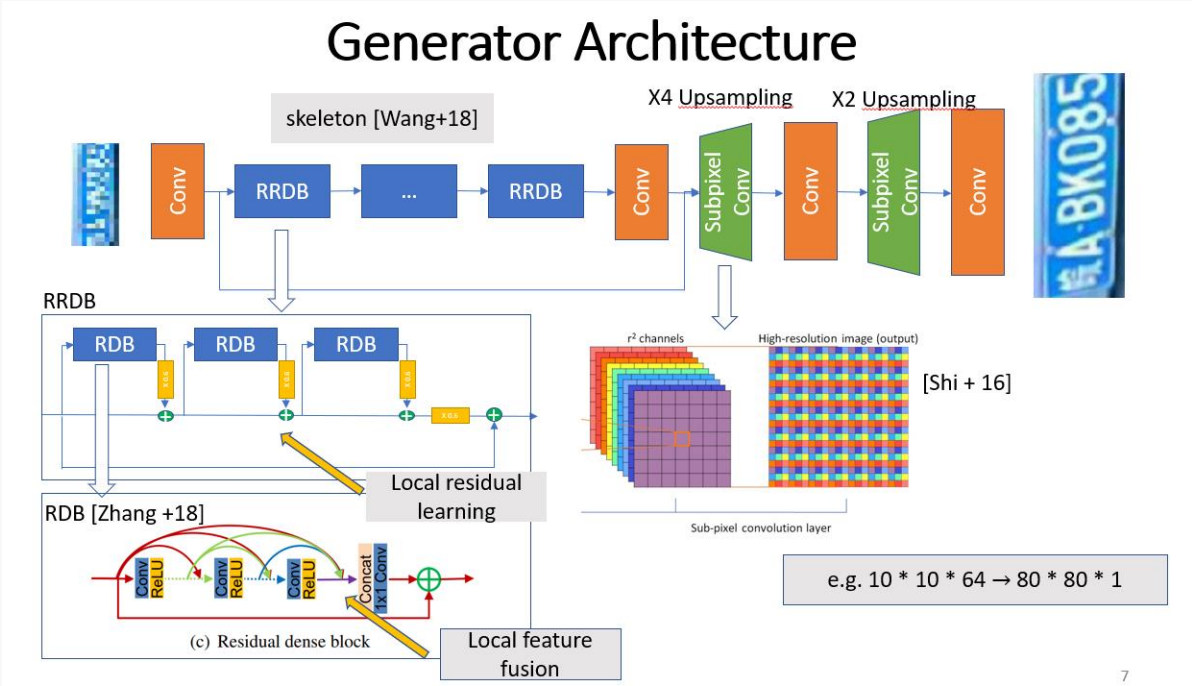


課題

ひび割れが小領域の角にしかない場合  
多数決では未検出となる

※ 従来のクラス定義によるデータを使用



■ ESRGANによる超解像タスクを利用



## ■ Generator Loss → 複数の値を基に決定

- Perceptual Loss ( $L_{\text{percep}}$ ) . . . 教師画像と生成画像のVGG特徴マップの絶対誤差
- Pixel Loss ( $L_1$ ) . . . 教師画像と生成画像の絶対誤差
- Adversarial Loss ( $L_G^{\text{Ra}}$ ) . . . 教師画像と生成画像の本物画像である確率の差

$$L_G^{\text{Ra}} = -\mathbb{E}_{x_r}[\log(1 - D_{\text{Ra}}(x_r, x_f))] - \mathbb{E}_{x_f}[\log(D_{\text{Ra}}(x_f, x_r))],$$

$$L_G = L_{\text{percep}} + \lambda L_G^{\text{Ra}} + \eta L_1,$$

$\lambda, \eta = \text{調整用係数}$

$$D_{\text{Ra}}(x_r, x_f) = \sigma(C(\text{Real}) - \mathbb{E}[C(\text{Fake})]) \rightarrow 1 \quad \text{More realistic than fake data?}$$

$$D_{\text{Ra}}(x_f, x_r) = \sigma(C(\text{Fake}) - \mathbb{E}[C(\text{Real})]) \rightarrow 0 \quad \text{Less realistic than real data?}$$

## ■ Discriminator Loss = ( $L_G^{\text{Ra}}$ + $L_D^{\text{Ra}}$ ) / 2

$$L_D^{\text{Ra}} = -\mathbb{E}_{x_r}[\log(D_{\text{Ra}}(x_r, x_f))] - \mathbb{E}_{x_f}[\log(1 - D_{\text{Ra}}(x_f, x_r))].$$

$$L_G^{\text{Ra}} = -\mathbb{E}_{x_r}[\log(1 - D_{\text{Ra}}(x_r, x_f))] - \mathbb{E}_{x_f}[\log(D_{\text{Ra}}(x_f, x_r))],$$




## ■ 値の固定と超解像画像の識別

- Pixel Loss(L1)の係数調整によるノイズの抑制
  - 3倍が適切
- 縮小倍率の検証
  - 1/4倍が適切
- 境界線の抑制
  - 再構成する方法を変更
- 超解像画像とバイキュービック補間により拡大した画像をCNNで識別
  - バイキュービック補間のほうが精度が高い

## ■ 実験①

### ■ プログラムミスの修正



■ **従来画像** → 未学習のひび割れ幅に対しても正常に検出

- ひび割れとして認定されていない局所的にあるひびに反応
- 訓練画像にない汚れに反応


	Precision	Recall	F_measure
生成画像	0.976	0.533	0.690
従来画像(BC補間)	0.792	0.813	0.802

## 画像1枚のみの識別結果の比較


[illegible]

➡ プログラムミスの可能性

- 画像に保存する際に正規化の関数が入っていた → 学習には影響なし
  - 関数を削除




修正前




修正後






ESRGAN



バイキュービック補間

生成画像(プログラム修正後)の識別結果




正検出 過検出 未検出 枠無：ひび割れ無し正検出

数字： 枠有：ひび割れ有りクラス尤度 枠無：ひび割れ無しクラス尤度



従来画像(バイキュービック補間)の識別結果




正検出 過検出 未検出 枠無：ひび割れ無し正検出

数字： 緑 赤：ひび割れ有りクラス尤度  
青 枠無：ひび割れ無しクラス尤度



従来画像の識別結果




正検出 過検出 未検出 枠無：ひび割れ無し正検出


数字： 緑枠：ひび割れ有りクラス尤度 赤枠：ひび割れ無しクラス尤度 青枠：枠無：ひび割れ無し正検出



ESRGAN



バイキュービック補間



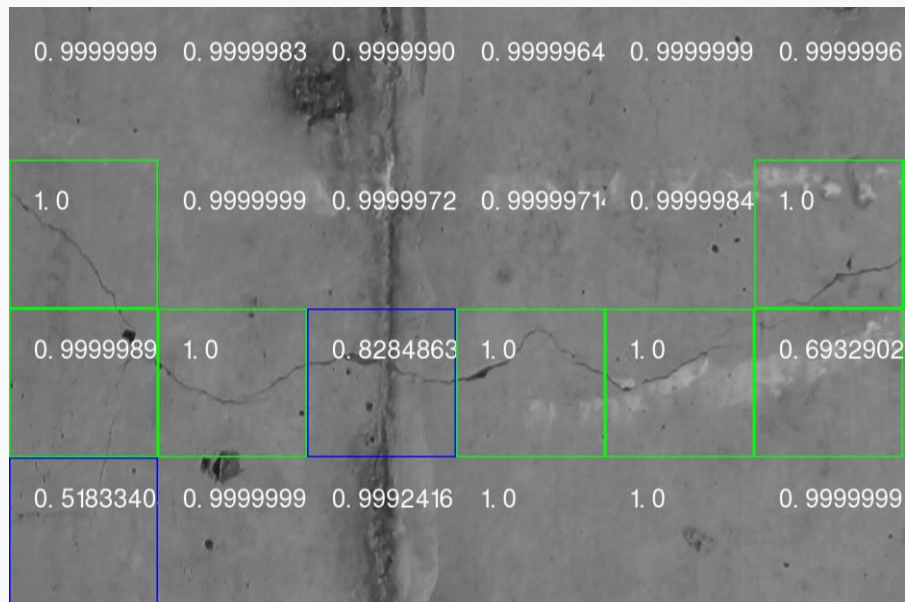
※画像1枚のみの識別結果の比較

	Precision	Recall	F_measure
生成画像(修正前)	0.976	0.533	0.690
従来画像(6枚結果)	0.949	0.856	0.904
生成画像(修正後)	0.767	0.797	0.782
従来画像(BC補間)	0.789	0.811	0.800

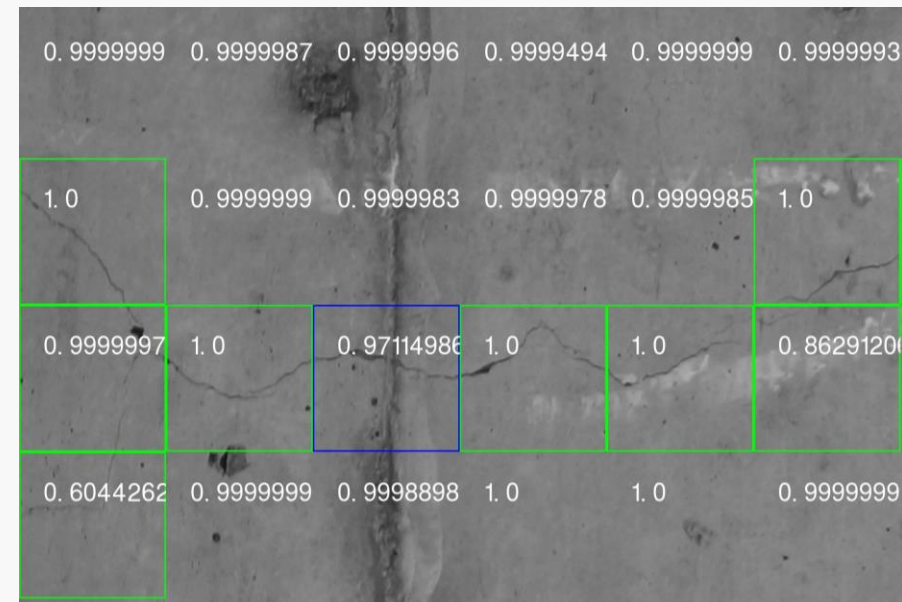
どちらも同じような識別結果になった




- 精度が低い → 明らかにひび割れがあるところを見逃している  
どちらも同じ個所で発生 → 未学習データ



ESRGAN




バイキュービック補間




4200×2700での識別結果

- 生成画像にノイズが乗っていたが、精度に大きな差は出なかった



ESRGAN



バイキュービック補間

## ■ まとめ

- プログラムミスを修正した
- 生成画像とバイキュービック補間の画像に大きな差は見られなかった。

## ■ 今後の予定

- 引き続きESRGANによる超解像を検証する
  - 低解像度のひび割れ画像に対してバイキュービック補間とESRGANによる拡大を行いCNNによる識別結果を比較する。



高解像度画像

同じひび割れ幅



低解像度画像

## ■ 実験①

- 縮小の倍率が高すぎる(済)→10/5
- 超解像での生成画像を従来サイズにするか倍のサイズにするかの検討(未)
- 提案システムの実装(未)

## ■ 実験②

- ガウシアンフィルタのパラメータの調整(済) →9/3
- 確率の調整(未)
- 薄いひび割れの定義と再現のための有効な変換(未)

## ■ 共通

- グレースケール画像で実験を行う(済) →9/3
- 数値による比較方法の検討 (先鋭化画像と比較) (未)
- Pixel Loss( $L_1$ )の係数調整によるノイズの抑制(済)→10/5

## ■ ESRGANについての検討は一旦終了

- バイキュービック補間による拡大画像を用いて前々回に考案したシステムを構築する

## ■ 卒論の研究の続きを行う

- CNN結果補正用の新しいアルゴリズム
- 訓練画像を中央にひび割れが有るものを利用

## ■ FCNの改良

- 訓練画像を中央にひび割れが有るものを利用(小さな穴に対しての過検出防止)
- ESRGANでも利用した画像の再構成方法を適用(小領域端の未検出防止)